Documentatie Lab2

Cerinta

- 1. Să se implementeze algoritmul *Tabu Search* pentru problema rucsacului.
 - a. Generare soluție inițială și vecin
 - b. Algoritm şi parametrizare
 - c. Experimente pe aceleaşi instanţe de la Tema 1
 - d. Comparații cu rezultatele obținute de căutarea locală

Citire si prelucrare date

Exact la fel ca in laboratorul 1

Pseudocod

```
Algorithm 1: Tabu Search
 Data: S - the search space, maxIter - the maximal number of
         iterations, f - the objective function, the definition of
         neighborhoods, and the aspiration criteria.
 Result: the best solution found
 Choose the initial candidate solution s \in S
 s^* \leftarrow s // Initialize the best-so-far solution.
 k \leftarrow 1
 while k \leq MaxIter do
     /* Sample the allowed neighbors of s */
     Generate a sample V(s,k) of the allowed solutions in N(s,k)
        // s' \in V(s,k) \iff (s' \notin T) \lor (a(k,s') = true)
     Set s to the best solution in V(s,k)
     /* Update the best-so-far if necessary */
     if f(s) < f(s^*) then
      s^* \leftarrow s
     end
     Update T and a
     /* Start another iteration */
     k \leftarrow k+1
  end
```

Implementare

- Parametri
 - objects = lista de obiecte
 - max_iter = numarul maxim de iteratii
 - bag_max_weight = capacitatea maxima a rucsacului
 - tabu_number = numarul de iteratii pentru care blocam flipuirea unui bit
 - fitness_function = functia de calculare a fitness-ului(defatul este valoarea obiectului)
- 1. Generarea random a unei solutii candidat initiale

```
# step 1
# generate a valid random solution
while True:
    solution_index, solution_binary = generate_solution(objects)
    rez = verify_solution(solution_binary, objects, bag_max_weight)
    if rez[0] is True:
        current_solution, current_fitness = solution_binary,
fitness_function(rez[1], rez[2])
        break
```

2. Initializarea celei mai bune solutii cu solutia initiala

```
best_solution = current_solution
best_fitness = current_fitness
```

3. Generarea vecinilor

```
# get neighbors
neighbors = get_neighbors_bit_index(current_solution)
```

4. Gasirea celui mai bun vecin non-tabu

```
# from neighborhood solutions, get the best candidate that is not on the Tabu
List(memory list)
if rez_neighbor[0] is True and fitness_neighbor > max_neighbour_non_tabu_fitness
and memory[index] == 0:
    max_neighbour_non_tabu_sol = point
    max_neighbour_non_tabu_fitness = fitness_neighbor
    memory_index_to_update = index
```

5. Actualizarea celei mai bune solutii daca este cazul

```
if max_neighbour_non_tabu_fitness > best_fitness:
    best_solution = max_neighbour_non_tabu_sol
    best_fitness = max_neighbour_non_tabu_fitness
```

6. Pentru iteratia urmatoare ne mutam in vecin chiar daca nu este mai bun decat solutia in care suntem

```
current_solution = max_neighbour_non_tabu_sol
current_fitness = max_neighbour_non_tabu_fitness
```

7. Actualizam memoria

```
# update the memory list with the best candidate solution in this iteration
memory[memory_index_to_update] = tabu_number
```

Toata functia

```
def tabu_search(objects, max_iter, bag_max_weight, tabu_number)
   best solution = ""
```

```
rez neighbor = verify solution(point, objects, bag max weight
best_fitness = max_neighbour_non_tabu_fitness
```

 Functia care genereaza venici este aceeasi ca la laboratorul 1, doar ca returneaza si indexul bitului flip-uit

Functia care face update la memorie este urmatoarea Pentru fiecare element din memorie, daca este diferit de 0 se decrementeza cu 1

```
def update_memory(memory):
    for index, elem in enumerate(memory):
        if elem > 0:
            memory[index] = elem - 1
```

Am rulat de cate 10 ori pentru o configuratie si am salvat cea mai buna solutie, cea mai slaba si media solutiilor

Experimente

Pentru fisierul cu 20 de obiecte

```
rucsac-20.txt
Tabu_number = 8
                       Best
                                                                  Worst
                                             Average
                                                                  621
 10 iter
                       726
                                             663
 100 iter
                       726
                                             722
                                                                  710
 1000 iter
                       726
                                             716
                                                                  696
                       726
                                             711
                                                                  671
 10000 iter
                       726
                                             712
                                                                  695
 100000 iter
```

Concluzii:

cele mai bune rezultate se obtin pentru 100 de iteratii

- solutia cea mai buna este aceeasi indiferent de numarul de iteratii
- se observa ca un numar de iteratii mai mare de 100 nu garanteaza o solutie mai buna

Comparatie cu rezultatele de la Steepest Ascent Hill Climbing

| Hill climbing | | | | |
|-------------------|----------------------|-------|--------|--|
| itness = sum=v | alue | | | |
| Numar obiecte = | 20 | | | |
| c=numar rulari(ni | umber_of_executions) | | | |
| | k=10 | k=100 | k=1000 | |
| Best | 726 | 726 | 726 | |
| Average | 681.8 | 722.8 | 726 | |

- se observa ca media solutiilor in acest caz creste cu cresterea numarului de iteratii, in timp ce la tabu search nu se intampla acest lucru
- In ambele cazuri se obtine aceeasi cea mai buna solutie indiferent de numarul de iteratii cu care s-au efectuat experimentele
- Pentru fisierul cu 200 de obiecte

rucsac-200.txt

 Tabu_number = 80

 Best
 Average
 Worst

 10 iter
 132547
 131526
 130534

 100 iter
 133033
 132541
 132038

132651

132104

Concluzii:

1000 iter

cele mai bune rezultate s-au obtinut cu 1000 de iteratii
 Comparatie cu rezultatele de la Steepest Ascent Hill Climbing

133235

| Fitness = sum=value Numar obiecte = 200 | | | | |
|--|--------------|-------------|-------------|--|
| | k=10 | k=100 | k=1000 | |
| Best | 132057 | 132815 | 133276 | |
| Average | 122723.78166 | 122690.3588 | 122999.0628 | |

• tabu search cu tabu-number=80 ofera rezultate ceva mai bune decat sahc, insa cele mai bune solutie in ambele cazuri(indiferent de numarul de iteratii) sunt foarte apropiate. Media solutiilor la tabu_search este mai buna.

Cerinta

- 2. Să se implementeze algoritmul *Simulated Annealing / Tabu Search* (la alegere) pentru problema TSP (instanța este indicată la laborator).
 - Generare soluție inițială și vecin
 - b. Algoritm şi parametrizare
 - c. Experimente pe o instanță TSP din lista de mai jos

Am ales sa implementez Simulated Annealing

Citire si prelucrare date

Fisierul pe care am lucrat este lin105.tsp

```
Read cities data from file
cities = [
```

Functia de mai sus parcurge fisierul, citeste datele din header apoi fiecare linie cu orase si adauga intr-o lista triplete de forma index_oras, prima coordonata, a doua coordonata.

Pe urma fieacare triplet din lista este transformat intr-un obiect de tip oras astfel:

```
def set_data(filename):
    """
    Transform the list of cities read from file into a list of city objects
    :param filename: the name of the file
    :return: a list of city objects and dimension
    """
    cities, dimension = read_city_data(filename)
    cities_object_list = []
    for elem in cities:
        cities_object_list append(City(elem[0], elem[1], elem[2]))
    return cities_object_list, dimension
```

Unde clasa CIty este urmatoarea:

```
class City:
    def __init__(self, index, x, y):
        """
            :param index: the city index from the file
            :param x: x coordinate
            :param y: y coordinate
            """
            self.index = index
            self.x = x
            self.y = y

def get_distance_from_city(self, other_city):
            """
            Compute the euclidian distance between two cities
            :param other_city: the city to find distance between
            :return: the distance as floating number
            """
            x_dif = self.x - other_city.x
            y_dif = self.y - other_city.y
            dist_euc_2d = math sqrt(x_dif * x_dif + y_dif * y_dif)
            return dist_euc_2d
```

Metrica folosita pentru calcularea distantei dintre orase este distanta euclidiana in 2D Lista cu biectele de tip oras si numarul lor le salvez intr-un obiect *Data* de unde vor fi transmise celorlalte clase

```
class Data:
```

```
A class for storing the initial list of city objects and dimension

"""

def __init__(self, filename):
    self.cities, self.dimension = set_data(filename)

def get_city(self, index):
    return self.cities[index]
```

Implementare

a. Generare solutie initiala si vecin

- O solutie valida reprezinta o permutare a oraselor (=un traseu care sa viziteze toate orasele o singura data)
- Calitatea solutiei reprezinta distanta totala a traseului la care se adauga distanta de la ultimul oras vizitat pana la orasul de inceput
- Distanta totala = suma distantelor dintre cate doua orase in ordinea de parcurgere a acestora
- Pentru reprezentarea unei solutii am implementat o clasa Route care retine o permutare a oraselor, numarul de orase(=dimensiunea) si calitatea solutiei(=distanta)

```
configuration of all cities
       :return: a Route object with random cities order
```

```
random randint
Get the cities indexes from the route
```

- Generarea solutiei initiale se face prin generarea aleatoare a unei permutari a oraselor (metoda get_random_route amesteca(sfuffle) orasele si returneaza o permutare)
- Un vecin = o permutare rezultata de la permutarea initiala prin interschimbarea a doua orase(2-swap) si este realizata de metoda swap_2_cities

a. Algoritm si parametrizare

Implementarea algoritmului se bazeaza pe pseudocodul din seminarul 2:

Exemplu aplicare SA pentru TSP:

```
T = 10000; alpha = 0.9999; minT = 0.00001;

c = createRandomSolution();

while (T > minT)

repeat

x = GetVecin(c); // swap 2 cities / 2-opt / etc

delta = eval(x) - eval(c);

if (delta < 0) then c = x

else if random.NextDouble() < Math.Exp(-delta/T) then c=x

until (max-iterations)

T = alpha*T;

end while

return c
```

Pentru implementare am creat clasa SimulatedAnnealing

```
cities dimension
       self max iterations = max iterations
           while iterations > 0:
```

```
iterations -= 1
```

Parametri

- temperature = temperatura maxima, initiala
- min_temperature = temperatura minima, de oprire (halting criteria)
- max_iterations = numarul maxim de iteratii (termination crieteria)
- alpha = un coeficient utilizat pentru a scadea temperatura
- cities = lista de orașe
- dimension = numarul de orase

Observatie!

• Metoda *simulated_annealing_alg* (metoda 1) implementeaza exact speudocodul din seminar, dar a doua metoda *simulated_annealing_alg2* (metoda 2) interschimba cele doua conditii de oprire.

- In primul caz temperatura este conditie exterioara, iar numarul de iteratii conditie interioara.
- In al doilea caz temperatura este conditie interioara, iar numarul de iteratii conditie exterioara.

Modificarea aceasta influenteaza considerabil timpul de rulare. Primul caz este mai costisitor din acest punct de vedere.

c. Experimente pe o instanta TSP din lista

Experimentele au fost efectuate pe fisierul lin105.tsp, iar din documentatia corespunzatoare, cel mai bun rezultat obtinut este 14379.

Metoda 1

Rezultatele experimentelor

Metoda 1 temperatura in exterior

T=1 t min=0.0001 Alpha = 0.999

| | Best | Average | Worst |
|-----------|-----------|-----------|-----------|
| 10 iter | 25814.206 | 29685.307 | 35779.202 |
| 100 iter | 24945.616 | 27414.698 | 32246.828 |
| 1000 iter | 23284.562 | 29177.623 | 33457.722 |

T=10 t min=0.001 Alpha=0.99

| | Best | Average | Worst |
|------------|-----------|-----------|-----------|
| 10 iter | 30876.056 | 35363.336 | 39561.993 |
| 100 iter | 24413.670 | 27378.791 | 33311.428 |
| 1000 iter | 21915.833 | 25916.316 | 28308.154 |
| 10000 iter | 22113.633 | 25612.025 | 34256.523 |

T=1000 t_min=0.1 Alpha=0.9

| | Best | Average | Worst |
|-----------|-----------|------------|-----------|
| 10 iter | 52276.355 | 55784.855 | 60926.680 |
| 100 iter | 27570.164 | 308529.201 | 37522.477 |
| 1000 iter | 21633.260 | 23672.017 | 2589.135 |

T=10000 t min=0.001 Alpha=0.99

| | Best | Average | Worst |
|-----------|-----------|-----------|-----------|
| 10 iter | 28041.795 | 31258.816 | 34833.373 |
| 100 iter | 21055.641 | 23198.165 | 25487.260 |
| 1000 iter | 18107.581 | 19149.523 | 20616.221 |

- Cele mai bune rezultate(mai apropiate de 14379) se obtin cu ultima configuratie si 1000 de iteratii (avand un timp de rulare de approximativ 4 ore)
- Cu cat alpha este mai apropiat de 1 si diferenta dintre temperatura initiala si temperatura minima este mai mare, cu atat se obtin solutii mai bune, insa timpul de executie creste considerabil
- Valorile empirice rezultate din a doua configuratie nu valideaza ipoteza intuitiva conform careia calitatea solutiei creste mereu cu cresterea numarului de iteratii.
 Pentru 10000 de iteratii rezultatele experimentale sunt mai slabe calitativ decat

pentru 1000 de iteratii, doar in media colutiilor se observa o foarte mica imbunatatire care poate fi pur intamplatoare.

Metoda 2

Rezultatele experimentelor

Metoda 2 temperatura in interior

T=10000 t_min=0.00001 Alpha=0.9999

| | Best | Average | Worst |
|------------|-----------|-----------|-----------|
| 10 iter | 20612.039 | 23350.448 | 25345.700 |
| 100 iter | 19590.789 | 22741.864 | 24687.640 |
| 1000 iter | 24737.013 | 29194.503 | 33917.256 |
| 10000 iter | 19748.678 | 23675.926 | 27535.024 |

T=100000 t_min=0.00001 Alpha=0.9999

| | Best | Average | Worst |
|-------------|-----------|-----------|-----------|
| 10 iter | 22355.972 | 23840.150 | 25964.179 |
| 100 iter | 22362.572 | 23710.788 | 26955.502 |
| 1000 iter | 21640.513 | 23893.423 | 25272.797 |
| 10000 iter | 20400.899 | 23311.330 | 26096.23 |
| 100000 iter | 22214.075 | 23796.507 | 26683.074 |

T=1000000 t min=0.00001 Alpha=0.9999

| | Best | Average | Worst |
|------------|-----------|-----------|-----------|
| 10 iter | 19879.688 | 22476.159 | 23657.041 |
| 100 iter | 19470.220 | 22754.836 | 26145.042 |
| 1000 iter | 20101.215 | 23014.039 | 25660.507 |
| 10000 iter | 21733.366 | 23681.777 | 24944.078 |

- Cele mai bune rezultate au fost obtinute cu 100 de iteratii in ultima configuratie
- Nu putem stabili o legatura generala intre cresterea numarului de iteratii si cresterea calitatii solutiei.
- Cu cat temperatura este mai mare, din experimente pare ca solutia are o calitate mai buna(exemplu cele mai bune solutii din ultimul tabel)